Universidade de Coimbra

DEPARTAMENTO DE ENGENHARIA INFORMÁTICA

Compiladores 2013/2014

Compilador para linguagem iJava

Autor:
David CARDOSO
Número: 2011164039

Bruno CACEIRO Número: 2008107991

Autor:

Índice

1	Introdução	2
2	Análise Lexical 2.1 Tokens	3
	2.1.1 Comentários	5 5
3	Análise Sintática e Semântica	6
	3.1 Gramática 3.1.1 Gramática Inicial 3.1.2 Gramática Final 3.1.2 Gramática Final	7 7 8
	3.2 Tratamento de Erros Sintáticos	11 12 12
	3.3.2 Criação da Árvore 3.3.3 Exemplo 3.4 Análise Semântica	14 15 16
	3.5 Tabela de Símbolos	17 17
4	3.6 Tratamento de Erros Semânticos	18 19
5	Conclusão	19

1 Introdução

Este projecto consiste no desenvolvimento de um compilador para a linguagem iJava (imperative Java), que consiste num pequeno subconjunto da linguagem Java (versão 5.0). Os programas da linguagem iJava são constituídos por uma única classe (a principal), contendo necessariamente um método main, e podendo conter outros métodos e atributos, todos eles estáticos e (possivelmente) públicos.

O projecto foi estruturado em 3 fases, primeiramente foi feita a Análise Lexical, implementada na linguagem C e utilizando a ferramenta lex. A segunda fase consistiu na análise sintática, recorrendo ao yacc/bison, com a construção da árvore de sintaxe abstrata e análise semântica (tabelas de símbolos, deteção de erros semânticos). No final foi feita a geração de código, em LLVM.

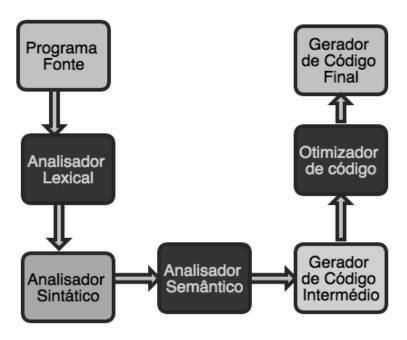


Figura 1: Fases de Compilação

2 Análise Lexical

A Análise Lexical consiste em analisar a entrada de linhas de caracteres e produzir uma sequência de símbolos (tokens) que podem ser manipulados mais facilmente por um parser. Assim, é uma forma de verificar um determinado alfabeto, neste caso o alfabeto da linguagem iJava. Esta análise pode ser dividida em três fases:

- Extração e classificação de tokens;
- Eliminação de delimitadores e comentários;
- Tratamento de erros;

2.1 Tokens

- ID: Sequências alfanuméricas começadas por uma letra, onde os símbolos "_"e "\$" contam como letras. Maiúsculas e minúsculas são consideradas ID's diferentes (case sensitive).
 - Expressão Regular: $[a-zA-Z_\$]([a-zA-Z_\$0-9])*$
- INTLIT: Sequências de dígitos decimais e sequências de dígitos hexadecimais (incluindo a-f e A-F) precedidas de "0x"
 - Expressão Regular: (([0-9]) + |("0x"[0-9a-fA-F]+))
- BOOLLIT: "true" | "false"
- **INT:** "int"
- BOOL: "boolean"
- **NEW**: "new"
- IF: "if"
- ELSE: "else"
- WHILE: "while"
- **PRINT:** "System.out.println"
- PARSEINT: "Integer.parseInt"
- CLASS: "class"
- **PUBLIC:** "public"
- STATIC: "static"
- VOID: "void"

• STRING: "String"

• DOTLENGTH: ".length"

• RETURN: "return"

• OCURV: "("

• CCURV: ")"

• OBRACE "{"

• CBRACE: "}"

• OSQUARE: "["

• CSQUARE: "]"

• ASSIGN: "="

• **SEMIC:** ";"

• COMMA: ","

Para a Análise Sintática foi necessário separar alguns *tokens* devido às diferentes prioridades que cada operador tem. Assim, os *tokens* foram agrupados pela ordem de precedência de operações.

• OP1: "&&"

• OP1OR: "| |"

• OP2: "<" | ">" | "<=" | ">="

• OP2EQS: "=="| "!="

• OP3: "+" | -"

• OP4: "*" | "/" | "%"

• NOT: "!"

O *iJava* é um subconjunto da linguagem *Java*, como tal, existe um conjunto de funcionalidades que embora não sejam suportadas, têm de ser consideradas. Assim, foi necessário tratar todo um conjunto de palavras reservadas de forma a permitir que sejam lexicalmente válidas mas não sintaticamente.

• RESERVED:

abstract | assert | break | byte | case | catch | char | const | continue | default | do | double | enum | extends | final | finally | float | for | goto | implements | import | instanceof | interface | long | native | package | private | protected | short | strictfp | super | switch | synchronized | this | throw | throws | transient | try | volatile | null | ++ | --

2.1.1 Comentários

Existem duas maneiras de fazer comentários:

Comentar apenas uma linha "//<código>".
 Caso seja detectado (//) todo o código que se segue é ignorado até encontrar uma mudança de linha.

```
Expressão Regular: "//".*
```

• Comentar um bloco de código "/*<código>*/"

Listing 1: Detecção de Comentários

Caso seja detectado (/*) todo o código é ignorado até que seja encontrado o seu correspondente (*/). Caso seja detectado o EOF então é apresentada uma mensagem de erro: "Line %d, col %d: unterminated comment". Foi criado um estado adicional no *lex* para poder tratar esta situação. Foi a criação deste estado que permitiu ignorar todos os *tokens* presentes dentro do comentário.

2.1.2 Tratamento de Erros

Se forem detectados erros lexicais no ficheiro de entrada então é impressa uma mensagem de erro no stdout:

- "Line<num linha>,col<num coluna>:illegal character('<c >'\n)"
- "Line<num linha>,col<num coluna>:unterminated comment\n"

Para podermos imprimir as mensagens de erro com o número da linha e coluna criámos uma variável *column* para poder contar as colunas e utilizamos a variável *yylineno*, disponibilizada pelo *yacc*, para sabermos o número das linhas. Para a contagem de colunas aumentamos a variável referente às colunas consoante o tamanho de cada *token*. Quando há uma mudança de linha, inicializa-se o contador das colunas a 1.

Para tratar o caso dos comentários criámos duas variáveis adicionais (Commentline, Commentcolumn) para poder guardar a coluna e linha onde o comentário é inicializado.

3 Análise Sintática e Semântica

De forma a realizar a análise sintática foi utilizada a ferramenta *lex*, para reconhecer e isolar os *tokens*, sendo que de seguida serão enviados para o *yacc* que irá ser responsável por verificar se estes pertencem à gramática da linguagem.

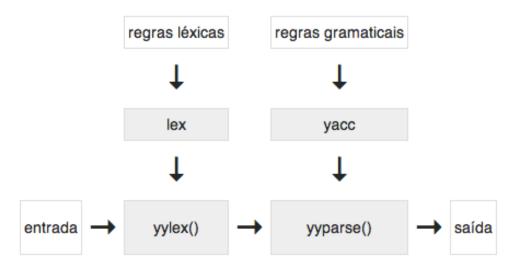


Figura 2: Relacionamento entre lex e yacc, retirado de http://pt.wikipedia.org/wiki/Yacc

Para realizar a ligação entre o yacc e o lex foram definidos tokens no yacc, posteriormente importados pelo lex. Sempre que o lex detecta uma sequência de caracteres correspondente a um token válido retorna um código acordado entre o yacc e lex de forma a identificar de forma única esse token (enums), sendo este valor enviado para o yacc. Caso o token corresponda a um tipo passível de ser processado (INTLIT, BOOLIT, ID e operadores), é guardado na variável yyvar o valor introduzido pelo utilizador.

Sendo a variável *yylval* também responsável por definir o tipo de retorno de cada regra da gramática, foi necessário acrescentar outros tipos de dados, de forma a permitir a criação da árvore de sintaxe abstrata. Assim, foi criada uma *union*, definida no *yacc*,que permite partilhar, no mesmo espaço de memória, vários tipos diferentes.

```
%union{
    struct _Node* node;
    char* token;
    struct _idList* listId;
    int type;
}
```

Listing 2: Union

Para permitir a percepção, pelo *yaac*, da linha e coluna que estão atualmente a serem utilizadas, foram também declaradas várias variáveis externas, partilhadas pelo *lex*.

```
extern int column;
extern int yylineno;
extern char* yytext;
extern int yyleng;
```

3.1 Gramática

A gramática é a maneira formal de especificar a sintaxe de uma linguagem. Desenvolver uma gramática não ambígua é um dos passos mais importantes para o sucesso de um compilador. Para a gramática da linguagem iJava usámos a notação **BNF** ($Backus\ Naur\ Form$), visto que a mesma é utilizada pelo yaac e permite remover as ambiguidades.

3.1.1 Gramática Inicial

 $Start \rightarrow Program$

 $Program \rightarrow CLASS ID OBRACE FieldDecl | MethodDecl CBRACE$

 $FieldDecl \rightarrow STATIC VarDecl$

 $MethodDecl \rightarrow PUBLIC STATIC (Type | VOID) ID OCURV$

[FormalParams] CCURV OBRACE VarDecl Statement CBRACE

FormalParams \rightarrow Type ID COMMA Type ID

Formal Params \rightarrow STRING OSQUARE CSQUARE ID

 $VarDecl \rightarrow Type ID COMMA ID SEMIC$

Type \rightarrow (INT | BOOL) [OSQUARE CSQUARE]

 $Statement \rightarrow OBRACE \ Statement \ CBRACE$

Statement \rightarrow IF OCURV Expr CCURV Statement [ELSE Statement]

 $Statement \rightarrow WHILE OCURV Expr CCURV Statement$

Statement \rightarrow PRINT OCURV Expr CCURV SEMIC

 $Statement \rightarrow ID$ [OSQUARE Expr CSQUARE] ASSIGN Expr SEMIC

 $Statement \rightarrow RETURN [Expr] SEMIC$

 $\text{Expr} \rightarrow \text{Expr}$ (OP1 | OP2 | OP3 | OP4) Expr

 $\operatorname{Expr} \to \operatorname{Expr} \operatorname{OSQUARE} \operatorname{Expr} \operatorname{CSQUARE}$

 $\text{Expr} \rightarrow \text{ID} \mid \text{INTLIT} \mid \text{BOOLLIT}$

 $\mathsf{Expr} \to \mathsf{NEW}$ ($\mathsf{INT} \mid \mathsf{BOOL}$) OSQUARE Expr CSQUARE

Expr o OCURV Expr CCURV

 $\text{Expr} \rightarrow \text{Expr}$ DOTLENGTH | (OP3 | NOT) Expr

 $\mathsf{Expr} \to \mathsf{PARSEINT}$ OCURV ID OSQUARE Expr
 CSQUARE CCURV

 $\text{Expr} \to \text{ID OCURV}$ [Args] CCURV

 $\mathrm{Args} \to \mathrm{Expr} \ \mathrm{COMMA} \ \mathrm{Expr}$

Lembramos que, em notação **ENBF**, os símbolos [...] englobam tokens opcionais e $\{...\}$ implicam a repetição dos tokens 0 ou mais vezes.

3.1.2 Gramática Final

A gramática que nos foi dada era ambígua e por isso tivemos de efetuar diversas alterações para permitir a análise sintática ascendente com o *yacc*. Algumas das alterações que efetuámos foram:

- Criação de estados adicionais para as regras que implicam a repetição de tokens.
- Criação de estados adicionais para as regras que continham tokens opcionais
- Estabelecimento de regras de prioridade de forma a gerir regras de precedência entre operadores
- Definição das regras de associação dos operadores (à esquerda/direita)

```
%nonassoc IFX
%nonassoc ELSE

%left OP1OR
%left OP2
%left OP2
%left OP2
%left OP3
%left OP4
%right NOT
11 %left OSQUARE DOTLENGTH
```

Listing 4: Associação de Operadores

Apesar de termos usado recursividade à direita, visto ser mais intuitiva, uma solução mais eficiente seria utilizar recursividade à esquerda, pois assim teríamos em memória apenas os elementos que estaríamos a analisar visto que estamos a efetuar reduções à medida que estamos a ler o *input*.

Foram ainda necessárias realizar alterações na gramática, de forma a impedir a indexação de arrays (a[1][2]). Para tal as expressões foram divididas em dois tipos, expressões indexáveis e não indexáveis.

A gramática final, utilizada no yacc é a seguinte apresentada.

```
FieldDecl:
           STATIC VarDecl_REPETITION;
MethodDecl:
           PUBLIC STATIC method_type_declaration ID OCURV FormalParams CCURV
   OBRACE VarDecl_REPETITION statement_declaration_REPETITION CBRACE;
method_type_declaration:
           Type
           VOID
FormalParams:
           Type ID several_FormalParams
           STRING OSQUARE CSQUARE ID
several_FormalParams :
           COMMA Type ID several_FormalParams
VarDecl_REPETITION:
           VarDecl_REPETITION
VarDecl:
           Type ID several_var_decl_in_same_instructionOPTIONAL SEMIC;
several\_var\_decl\_in\_same\_instructionOPTIONAL:
           COMMA ID several_var_decl_in_same_instructionOPTIONAL
Type:
           INT OSQUARE CSQUARE
           BOOL OSQUARE CSQUARE
           INT
           BOOL
statement_declaration_REPETITION:
           Statement\_declaration\_REPETITION
Statement:
           OBRACE several_statement CBRACE
           IF OCURV Expr CCURV Statement %prec IFX
           IF OCURV Expr CCURV Statement ELSE Statement
           WHILE OCURV Expr CCURV Statement
```

```
PRINT OCURV Expr CCURV SEMIC
            ID array_indexOPTIONAL ASSIGN Expr SEMIC
            RETURN return_expression SEMIC
several_statement:
            Statement several_statement
array\_indexOPTIONAL:
            OSQUARE Expr CSQUARE
return_expression :
            Expr
IndexableExpr:
            INTLIT
            BOOLLIT
            ID OCURV Args_OPTIONAL CCURV
            OCURV Expr CCURV
            Expr DOTLENGTH
            IndexableExpr OSQUARE Expr CSQUARE
            PARSEINT OCURV ID OSQUARE Expr CSQUARE CCURV
Expr:
            Expr OP1 Expr %prec OP1
            Expr OP1OR Expr %prec OP1OR
            Expr OP4 Expr %prec OP4
            Expr OP3 Expr %prec OP3
            Expr OP2 Expr %prec OP2
            Expr OP2EQS Expr %prec OP2EQS
            OP3 Expr %prec NOT
            NOT Expr %prec NOT
           NEW INT OSQUARE Expr CSQUARE
            NEW BOOL OSQUARE Expr CSQUARE
            Indexable Expr\\
Args_OPTIONAL:
            Args
Args:
            Expr comma_expr;
comma\_expr:
```

```
COMMA Expr comma_expr
```

Listing 5: Gramática Final

3.2 Tratamento de Erros Sintáticos

Para o tratamento de erros sintáticos utilizamos a função yyerror que imprime a linha, a coluna e o input onde ocorreu o erro através da utilização das variáveis yylineno, column, yytext. Assim, sempre que é detetado um erro um sintático é impressa uma mensagem de erro e terminada a execução do programa.

Listing 6: Função para tratamento erros sintáticos

3.3 Árvore de Sintaxe Abstrata

3.3.1 Estruturas

Para a construção da árvore de sintaxe abstrata, optámos por utilizar um nó genérico (Node) com a seguinte estrutura:

```
/* General Node */
2 typedef struct Node
      //Type of the Node (to identify the type of the node)
      NodeType n_type;
      //Type of the Struct (Int, Void, String,...)
      Type type;
      //Id or list of id's
10
      listID* id;
11
12
      //The Node's children (Method's/ Statements, Operators)
13
      struct _Node* n1;
14
      struct _Node* n2;
1.5
      struct _Node* n3;
16
17
      //Next node
18
      struct _Node* next;
20
      //Literals (to store the values)
2.1
      char* value;
22
    //Not used lololol
24
      char isStatic;
25
  } Node;
26
27
  /* Linked list of ID's (for multiple declaration of variables) */
  typedef struct _idList
30
31
    //ID
32
    char* id;
33
34
    //Next ID
35
    struct _idList* next;
36
  }listID;
```

Listing 7: Estruturas para representação de Nós da Árvore

Optámos por usar apenas uma única estrutura para representar toda a Árvore de Sintaxe Abstrata uma vez que qualquer nó poderia ser reduzido a um caso mais abstrato. Esta solução permitiu também que as operação realizadas sobre a árvore tenham sido simplificadas, visto não ser necessário realizar qualquer cast ou conversão de tipo. Uma vez que a linguagem iJava apresenta menos funcionalidades do que a linguagem Java, foi possível optar por esta representação, mas tal poderia não se adaptar a um projeto mais complexo.

```
/* Type of the Node (to identify the type of the node)
    - This enum allows us to uniquely identify each node and manipulate the data
       accordingly
  */
  typedef enum {NODEPROGRAM,
                 NODE_VARDECL,
                 NODE_METHODDECL,
                 NODE METHODPARAMS,
                 NODEMETHODBODY,
                 NODE_PARAMDECL,
                 NODE_COMPOUNDSTAT,
                 NODE_IFELSE,
11
                 NODE_PRINT,
13
                 NODE_RETURN,
                 NODE_STORE,
14
15
                 NODE_MUL,
                 NODE_DIV,
16
                 NODE_MOD,
17
                 NODE_NOT,
18
                 NODE_MINUS,
                 NODE_PLUS,
20
                 NODELENGTH,
21
                 NODELOADARRAY,
                 NODE_CALL,
23
                 NODE_NEWINT,
24
                 NODE NEWBOOL,
25
                 NODE_PARSEARGS,
26
                 NODE_WHILE,
27
                 NODE STOREARRAY,
28
                 NODE_INTLIT,
29
30
                 NODE_BOOLLIT,
                 NODE_ID,
31
                 NODE_AND,
32
                 NODE_OR,
33
                 NODELESS,
34
                 NODE_GREATER,
35
36
                 NODE_LESSEQUAL,
                 NODE_GREATEREQUAL,
37
                 NODE_DIFFERENT,
38
                 NODE_EQUAL,
39
                 NODE_NULL,
40
                 NODE_UNARYPLUS,
41
                 NODE_UNARYMINUS.
42
                 NODE_DONTPRINT
43
                } NodeType;
44
45
  /*Type of Node/Token (Int, Void, String,...) */
46
  typedef enum {TYPE_VOID,
47
              TYPE_INT,
48
              TYPE_BOOL,
49
              TYPE_INT_ARRAY,
50
              TYPE_BOOL_ARRAY,
51
              TYPE_STRING_ARRAY
```

} Type;

Listing 8: Identificadores únicos de cada Node

3.3.2 Criação da Árvore

```
1 /* Method to create an Id (a) */
2 listID * insertID (Node* currentNode, char* id);
3 /* Method to create a new VarId (int a,b,c (to link a to b to c)) */
4 listID * newVarID(char* id, listID * next);
5 /* Method to get an operator type (NODE.PLUS; NODE.NOT,...) */
6 NodeType getOperatorType(char* op);
7 /* Method to create a Null Node, used for mandatory child Nodes */
8 Node* createNull();
9 /* Method to create the Program itself (class gcd) */
10 Node* insertClass(char* id, Node* statements);
11 /* Method to create a new VarDecl (int a,b,c,d,e,f,g,h,i,j,k,l,m,n,o,p,q,r;)*/
12 Node* newVarDecl(int type, char* id, listID* moreIds, Node* next);
/* Method to link nodes */
14 Node* setNext(Node* current, Node* next);
/* Method to set a Node static */
Node* setStatic(Node* currentNode);
17 /* Creates a New Method Declaration Node:
    public static void cenas(){statement1; statement2; return;} */
19 Node* newMethod(int type, char* id, Node* params, Node* varDecl, Node*
     statements);
 /* Creates a Compound Node ({ expression1; expression2}) */
21 Node* insertCompound(Node* expression);
22 /* Creates an If node (if(true)) */
Node* insertIf(Node* expression, Node* statement1, Node* statement2);
24 /* Creates a Print Node (System.out.println("blica"))*/
25 Node* insertPrint(Node* expression);
26 /* Creates a While Node (while(true)) */
Node* insertWhile(Node* expression, Node* statements);
28 /* Creates a Return Node (return; return true;)*/
29 Node* insertReturn(Node* expression);
30 /* Creates a Store Node (a = 5, b[5] = true) */
Node* insertStore(char* id, Node* arrayIndex, Node* expression);
32 /* Creates a Terminal Node (a, 5, true, false) */
Node* createTerminalNode(int n_type, char* token);
34 /* Creates a New Param Declaration Node (String[] argv, int a) */
Node* newParamDecl(int type, char* id, listID* moreIds, Node* next);
36 /* Creates a .length Node (argv.length) */
Node* insertDotLength (Node* expression);
38 /* Creates a Load Array Node (c[1]) */
Node* insertLoadArray(Node* expression, Node* indexExpression);
40 /* Creates a parse int Node (Integer.parseInt(argv[1])) */
41 Node* insertParseInt(char* id, Node* indexExpression);
42 /* Creates a new array Node (new int[1]) */
| Node | insertNewArray(int type, Node | expression);
44 /* Creates a Method Call (teste(a,b)) */
45 Node* createCall(char* id, Node *args);
|*| Creates an unary expression (!true; -1;...)*/
```

```
Node* insertExpression(char* op, Node* exp);

/* Creates an binary expression ( 1 + 1; true != false; a < b) */

Node* insertDoubleExpression(Node* exp1, char* op, Node* exp2);

50
```

Listing 9: Funções para a criação da árvore

Para a criação da árvore é realizada pelo yacc uma análise ascendente do input, isto é, os nós vão sendo criados e agrupados de forma a representar a estrutura de cada regra gramatical. Assim, num primeira instância, são criados os nós terminais (declaração de variáveis, BOOLIT, INTLIT) sendo posteriormente agrupados a operadores e expressões de forma a criar a estrutura do programa.

3.3.3 Exemplo

Considerando o seguinte programa:

```
class gcd {
  public static void main(String[] args) {
    int x;
    return;
}
```

Listing 10: Programa Exemplo

A árvore gerada é a seguinte:

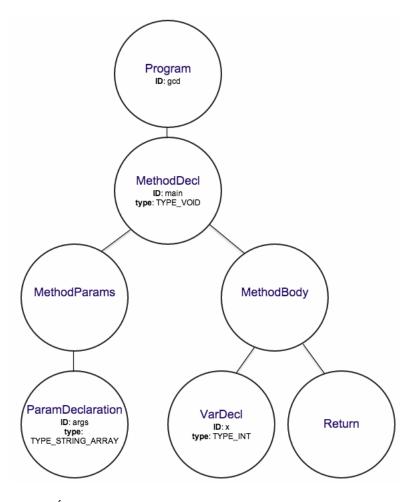


Figura 3: Árvore de Sintaxe Abstrata para o Programa Exemplo

3.4 Análise Semântica

A Análise Semântica tem como principais objectivos a ligação das definições de variáveis com a sua utilização, a verificação da correcção de tipos, declarações e chamadas de funções. Esta análise é dividida em duas fases:

- 1. Para cada scope no programa:
 - Processar as declarações:
 - Adicionar novas entradas na tabela de símbolos
 - Apresentar mensagem de erro caso haja variáveis repetidas
 - Processar os statements
 - Procurar variáveis que não foram declaradas neste scope ou no scope global,
 e caso não tenham sido, apresentar mensagem de erro
- 2. Processar todos os statements do programa outra vez
 - Usar a tabela de símbolos para determinar o tipo de cada expressão e procurar erros de tipo (atribuições, cálculos, contagem e tipos de argumentos correctos,...)

3.5 Tabela de Símbolos

A Tabela de símbolos é criada a partir da Árvore de Sintaxe Abstrata, onde se percorrem todos os nós relativos às declarações de métodos e atributos, sendo criada uma nova entrada na tabela para cada um deles.

3.5.1 Estruturas

Para representação da tabela de símbolos, foram utilizadas as seguintes estruturas:

```
/* Table Node */
  typedef struct _TableNode
      //Type of the Node (to identify the type of the node)
      TableType n_type;
      //Type of the Struct (Int, Void, String,...)
      Type type;
      //ID or list of id's
      listID* id;
11
12
      //Next node
      struct _TableNode* next;
14
      //If is a param
16
      char isParam;
17
  } TableNode;
18
19
  /* Table */
  typedef struct _Table{
21
      TableNode* table;
      struct _Table* next;
23
  } Table;
```

Listing 11: Estruturas para representação da Tabela de Símbolos

3.6 Tratamento de Erros Semânticos

Para o tratamento de erros semânticos utilizamos as seguintes funções:

```
/* Check if global variables have the same name as the Methods:
      - If they have print error message: "Symbol %s already defined" and exit
2
  */
         checkIfExists(char* id, Table* local);
  void
  void
         checkSemanticErrors(Node* ast, Table* local, Table* main);
5
         checkErrors(Node* ast, Table* symbols, Table* main);
  void
  /* Check if ID exists:
  - If exists return the Type
  - If doesn't exist, print error message: "Cannot find symbol %s\n" and exit
10
  */
11
         checkifIDExists(char* id, TableType type, Table* table, Table* main);
12 int
Table * getMethodTable(Table * main, char * methodID);
14
  /* Check if the Literal is valid (decimal / hexadecimal / octal)
15
  - If it is invalid print error message: "Invalid literal %s\n" and exit
16
17 */
18 void
         validIntLit(char* lit);
         checkTypes(Node* ast, Table* main);
19 void
         operatorError2Types(int op,int n1, int n2);
20 void
21 void
         operatorError1Types(int op, int n1);
22 void
         assignmentError(char* var, int n1, int n2);
         assignmentErrorArray(char* var, int n1, int n2);
  void
23
24 void
         setTable(Table * oi);
         getFunctionType();
25 int
26 void
         statementError(int op, int n1, int n2);
         statementError1oranother(int op, int n1, int n2, int n3);
  void
27
         getFunctionName();
28 char*
29 void
         getErrorCall(int i, char* name, int n1, int n2);
```

Listing 12: Funções para tratamento de erros semânticos

- 4 Geração de Código
- 5 Conclusão